IT5427 · TÍCH HỢP VÀ XỬ LÝ DỮ LIỆU LỚN · ĐỒ ÁN CUỐI KỲ

Pipeline xử lý log thời gian thực phát hiện log pattern chưa biết

Log của Windows, Linux, Mac · ánh xạ GAV · Kafka · Spark Structured Streaming · ClickHouse

Giảng viên: **Vũ Tuyết Trinh**
Nhóm: [Họ tên – MSSV] · [Họ tên – MSSV] · [Họ tên – MSSV]

Hà Nội, 11/2026

Bài toán

Ba hệ điều hành, ba cách ghi log.

Muốn xem chung thì phải đưa về một lược đồ. Sau đó mới tìm được mẫu log lạ ngay khi nó xuất hiện.

Windows

```
2016-09-28 04:30:31, Info CBS Ending…
```

Có mức log. Không ghi tên máy.

Linux, Mac

```
Jun 14 15:16:01 combo sshd[19939]: auth…
```

Có tên máy. Không ghi năm, không có mức log.

Mục tiêu 1
Thu thập log ba hệ điều hành

Mục tiêu 2
Đưa về một lược đồ bằng GAV

Mục tiêu 3
Nạp vào kho dữ liệu

Mục tiêu 4
Tìm mẫu lạ, cảnh báo

Thiết kế kiểu kho dữ liệu: ba bước

Log được lấy ra khỏi nguồn, biến đổi về lược đồ chung, rồi nạp vào một kho để truy vấn.

BƯỚC 1 · EXTRACT

Lấy log thô

Log Producer đọc tệp, đẩy lên Kafka. Không sửa nội dung.

BƯỚC 2 · TRANSFORM

Về lược đồ chung

Ánh xạ GAV, kiểm tra chất lượng, trích mẫu log.

BƯỚC 3 · LOAD

Nạp vào kho

ClickHouse tự đọc Kafka và ghi vào bảng.

Chạy liên tục trên luồng: không nạp theo lô định kỳ như kho dữ liệu truyền thống.

Ba nguồn dữ liệu

	Windows	Linux	Mac
Hệ thống	Windows 7, CBS.log	Máy chủ Red Hat	MacBook Pro
Số dòng	5 triệu	25.567	117.283
Thời gian	2016 – 2017	2005 – 2006	7/2017
Tốc độ đỉnh	35.411 dòng/giây	53 dòng/giây	4.009 dòng/giây
Số tiến trình	3	73	127

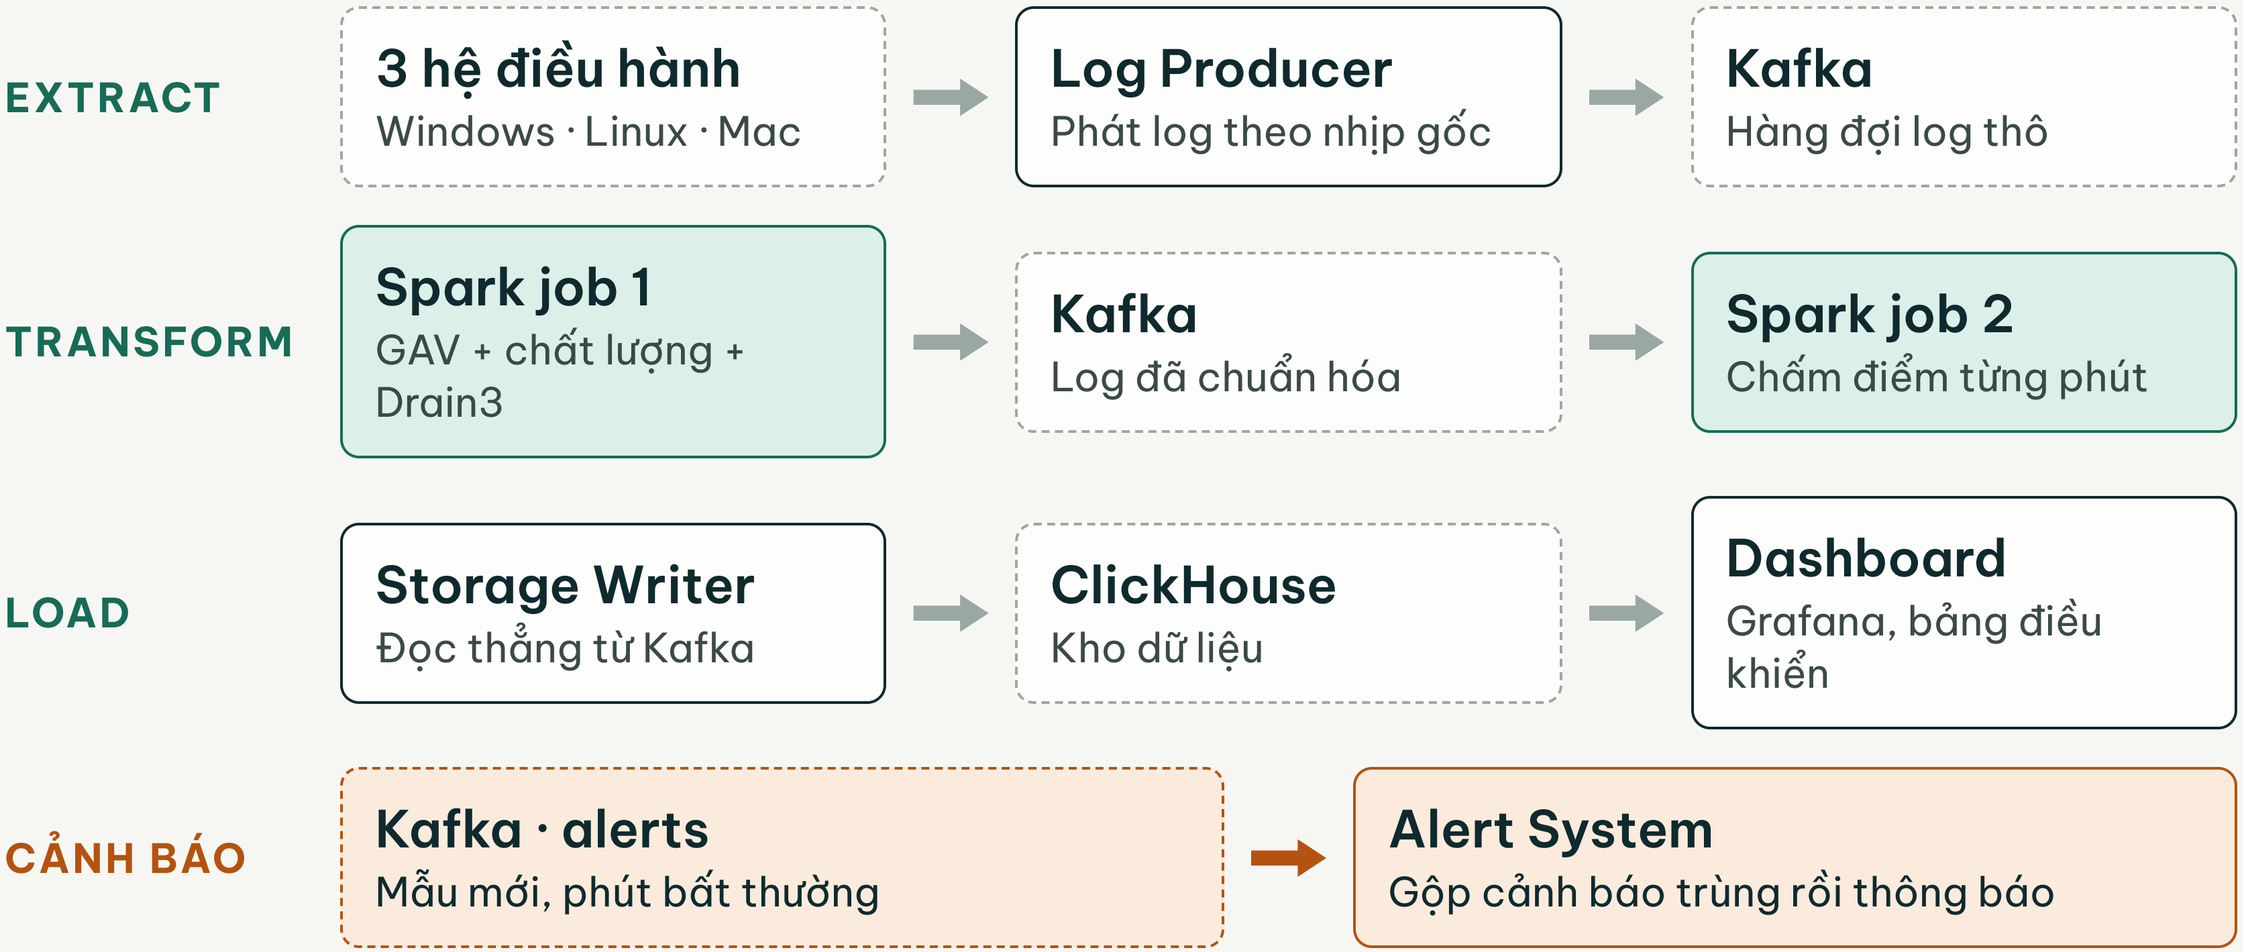
Khối lượng
1,2 GB, 5,1 triệu dòng

Tốc độ
Bùng nổ: 35.000 dòng một giây

Không có nhãn
Đánh giá bằng dòng chèn thử

Nguồn: Loghub. Windows: 5 triệu dòng đầu của tệp 26 GB (114 triệu dòng)

Kiến trúc theo ba bước



Ô xanh: ứng dụng Spark · Ô viền đứt: nơi chứa dữ liệu · Ô cam: luồng cảnh báo

Mỗi nguồn thiếu một thứ

Thông tin	Windows	Linux	Mac
Tên máy	**không ghi**	có	có, nhưng 38 tên
Mã tiến trình	**không ghi**	có ở 43% số dòng	có
Mức log	có	**không ghi**	**không ghi**
Năm	có	**không ghi**	**không ghi**
Múi giờ	**không ghi**	**không ghi**	**không ghi**

Lược đồ chung phải bù lại đúng chỗ mỗi nguồn thiếu.

Số liệu do công cụ lập hồ sơ nguồn của nhóm sinh ra

GAV: ba khung nhìn về một lược đồ

```
LogEvent ⊇ V_Windows(Windows) ∪ V_Linux(Linux) ∪ V_Mac(Mac)
```

LogEvent	Từ Windows	Từ Linux, Mac
event_time	giờ địa phương, đổi về UTC	thêm năm, đổi về UTC
host	một tên cố định	lấy từ dòng log
pid	null	lấy từ dòng log
level	lấy từ dòng log	null
severity	mức log + từ khóa	từ khóa trong nội dung

Khung nhìn được khai báo như dữ liệu. Thêm nguồn mới: thêm một khung nhìn.

Bốn chỗ lệch và cách bù

LINUX, MAC

Thiếu năm

Chọn năm sao cho ngày rơi vào khoảng thời gian đã khai báo của nguồn.

CẢ BA NGUỒN

Ba múi giờ

Windows UTC+8, Mac UTC−7, Linux giả định UTC. Tất cả đổi về UTC.

WINDOWS

Thiếu tên máy

Gán một tên cố định cho cả nguồn; mã tiến trình để null.

LINUX, MAC

Thiếu mức log

Suy từ từ khóa: failed → ERROR, out of memory → FATAL.

```
Jun 14 15:16:01 combo sshd[19939]: authentication failure
→ 2005-06-14T15:16:01Z · combo · sshd · pid 19939 · ERROR
```

Các hằng số (múi giờ, khoảng thời gian, tên máy) khai báo một chỗ trong sổ đăng ký nguồn

Dữ liệu không sạch

12,4%
dòng Mac phải cách ly

38 → 1
tên của cùng một máy Mac

82%
dòng Windows trùng nguyên văn

30.439
dòng Windows ghi Info nhưng báo lỗi

Tám luật chất lượng: cách ly, sửa hoặc gắn cờ. Không xóa dòng nào.

Cách ly: dòng lỗi vào topic riêng, kèm lý do.

Dòng trùng chỉ gắn cờ: đó là sự kiện thật.

Quét toàn bộ ba tệp bằng bộ luật chất lượng: 5 triệu dòng Windows, 25.567 dòng Linux, 117.283 dòng Mac

Phát hiện log lạ theo hai tầng

TẦNG 1 · DRAIN

Mẫu chưa biết

Học các mẫu từ 20% log đầu. Khi chạy, dòng nào không khớp mẫu đã học là **unknown**.

Giống liên kết bản ghi: có độ đo tương tự, có ngưỡng.

TẦNG 2 · ISOLATION FOREST

Phút bất thường

Đếm số lần mỗi mẫu xuất hiện trong từng phút. Mô hình chấm điểm phút nào khác thường.

Mô hình có sẵn, chỉ dùng để kiểm tra.

Mỗi phút nhận một kết luận: bình thường, có mẫu lạ, tần suất lạ, hoặc cả hai.

Trích mẫu đúng nhóm trên mẫu có đáp án: Windows 99,9% · Linux 69% · Mac 81%

Load: kho dữ liệu và Alert System

CLICKHOUSE

399.450 dòng trong một bảng

10,5×
nén dữ liệu

7 ms
đếm theo nguồn

8 ms
tìm một từ

ClickHouse tự đọc Kafka và ghi vào bảng. Không cần chương trình nạp riêng.

ALERT SYSTEM

Gộp cảnh báo trùng

6.341 → 32
cảnh báo thành thông báo

Báo khi có mẫu mới hoặc phút bất thường. Gửi ra màn hình, tệp, webhook.

Truy vấn chéo ba hệ điều hành (số dòng lỗi theo giờ): 11 ms · 6.341 bản ghi vẫn đủ trong bảng alerts

Chạy ba nguồn cùng lúc

	Windows	Linux	Mac
Dòng gửi vào	300.050	20.504	93.877
Bị cách ly	2.626	106	12.249
Vào kho	297.424	20.398	81.628
Dòng unknown	2.735	13.299	6.644
Dòng chèn bắt được	50 / 50	50 / 50	50 / 50

Hiệu năng

Job 1 xử lý khoảng 3.700 dòng mỗi giây với 2 lõi.

Bài học

Ba nguồn thuộc ba thời kỳ nên phải tách watermark cho từng nguồn.

Không mất dòng nào: số dòng vào kho bằng số dòng gửi trừ số dòng cách ly.

Windows 4.000 dòng/giây, Mac 1.200, Linux 300; mỗi nguồn chèn 50 dòng thuộc 5 mẫu lạ

Tìm được gì?

DÒNG CHÈN THỬ

100%

300 dòng mẫu lạ chèn vào ba nguồn đều bị bắt.

LINUX

10.404

dòng “Out of Memory: Killed process” từ 15/11/2005: máy chủ hết bộ nhớ.

MAC

3.930

lần lặp của một lỗi ứng dụng, xuất hiện từ ngày 05/07.

Hệ thống tìm ra sự cố thật mà không cần nhãn hay luật viết trước.

Isolation Forest chỉ bổ sung: bắt 36 trên 190 phút có dòng chèn · Windows: 0,3% dòng là mẫu mới

Kết luận

Đã làm được

- Kho dữ liệu log đủ ba bước
- GAV đưa ba hệ điều hành về một lược đồ
- Tám luật chất lượng, có cách ly
- Tìm ra sự cố thật trên Linux

Hạn chế

- Năm và múi giờ là giả định
- Mức độ suy từ từ khóa
- Dữ liệu không có nhãn

Hướng tiếp theo

- Ghép thông điệp nhiều dòng
- Thêm nguồn Android
- Bước xác nhận mẫu mới
- Đo trên nhiều máy

CẢM ƠN THẦY CÔ VÀ CÁC BẠN

Hỏi đáp

Nhóm sẵn sàng trình diễn trực tiếp: phát log ba hệ điều hành, chèn mẫu lạ, xem cảnh báo và tìm log trong kho dữ liệu.

Mã nguồn

`github.com/vudu151/LogPattenPipeLine`

Bảng điều khiển demo

`./pipeline.sh panel → localhost:8501`